

Movie Review Sentiment Analysis

Análise de Sentimentos em Avaliações de Filmes com NLP e Machine Learning

Curso Análise e Desenvolvimento de Sistemas — UNIMAR

Disciplina Inteligência Artificial / Machine Learning

Avaliação Projeto Avaliativo P2 — 2026/1

Integrantes:

Nome	RA
Guilherme Vicente	1992017
Integrante 2	XXXXXXX
Integrante 3	XXXXXXX

1. Descrição do Problema

Com a popularização das plataformas de streaming e sites de avaliação de filmes, milhares de reviews são publicadas diariamente. Analisar manualmente todas essas opiniões é inviável, tornando necessária a utilização de técnicas de Inteligência Artificial capazes de identificar automaticamente se uma avaliação expressa um sentimento positivo ou negativo.

Este projeto aborda esse desafio por meio de um pipeline completo de Processamento de Linguagem Natural (NLP), desde a limpeza dos dados brutos até o deploy de uma aplicação web interativa.

2. Objetivo do Projeto

Desenvolver um modelo de Machine Learning capaz de classificar automaticamente avaliações de filmes em inglês como **positivas** ou **negativas**, utilizando técnicas de NLP, e disponibilizá-lo via aplicação web com Streamlit.

Tipo de problema: Classificação Supervisionada Binária Classe 1 = Positive | Classe 0 = Negativo

3. Dataset Utilizado IMDB Dataset

Característica	Detalhe
Total de reviews	50.000 (após remoção de 418 duplicatas: ~49.582)
Balanceamento	Base balanceada 25.000 positivas / 25.000 negativas
Tipo de dado	Textos reais de usuários em inglês
Arquivo	IMDB Dataset.csv
Uso comum	Benchmark amplamente utilizado em NLP

4. Metodologia

Carregamento dos Dados:	Leitura do dataset com <code>pd.read_csv()</code> , usando <code>engine="python"</code> e <code>on_bad_lines="skip"</code> para robustez.
Limpeza e Tratamento	Remoção de 418 duplicatas com <code>df.drop_duplicates()</code> . Criação da função <code>limpar_texto()</code> : conversão para minúsculas, remoção de tags HTML, pontuação e caracteres especiais.
Análise Exploratória (EDA)	Verificação de nulos, distribuição de sentimentos, boxplot de tamanho das reviews, nuvens de palavras, Top 10 bigramas e trigramas por classe.
Pré-processamento	Vetorização com <code>TfidfVectorizer(max_features=5000, stop_words="english")</code> . Divisão estratificada: 60% treino / 20% validação / 20% teste. <code>fit_transform()</code> apenas no treino para evitar data leakage.
Treinamento e Validação	Três modelos avaliados com <code>StratifiedKFold(k=3)</code> via <code>cross_validate()</code> : <code>MultinomialNB</code> , <code>LogisticRegression</code> , <code>LinearSVC</code> .
Avaliação Final	Modelo vencedor avaliado no conjunto de teste isolado (20%), garantindo métricas sem viés.
Salvamento	Modelo e vetorizador salvos com <code>joblib.dump()</code> em <code>model/modelo_final.pkl</code> e <code>model/vetorizador.pkl</code> .

5. Modelos Treinados

Modelo	Classe Python	Características
Multinomial Naive Bayes	<code>MultinomialNB()</code>	Modelo probabilístico rápido. Assume independência entre palavras.
Regressão Logística	<code>LogisticRegression(max_iter=1000)</code>	Usa curva matemática para ajustar o peso de cada palavra. Melhor interpretabilidade.
Support Vector Machine Linear	<code>LinearSVC(dual=False)</code>	Modelo geométrico que traça hiperplano separador entre as classes.

6. Resultados — Comparativo dos Modelos (Cross-Validation)

Os três modelos foram avaliados com **StratifiedKFold k=3** sobre o conjunto de treino (60% dos dados). As métricas abaixo representam a média dos 3 folds:

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
MultinomialNB	0.8527	0.8512	0.8551	0.8531	0.9320
LogisticRegression	0.8891	0.8872	0.8919	0.8895	0.9540
LinearSVC	0.8750	0.8739	0.8764	0.8751	0.9490

Modelo vencedor: Logistic Regression melhor desempenho em todas as métricas, especialmente AUC-ROC de 0.954, indicando excelente capacidade discriminativa.

Matrizes de Confusão — Conjunto de Validação

Modelo	VP (TN)	FP	FN	VP (TP)	Erro Total
MultinomialNB	4239	761	697	4303	1458
LogisticRegression	4325	675	514	4486	1189
LinearSVC	4314	686	561	4439	1247

7. Avaliação Final no Conjunto de Teste

Após a seleção do modelo final, a Regressão Logística foi avaliada uma única vez sobre o conjunto de teste — 20% dos dados (10.000 reviews) completamente isolados desde o início do projeto. Esta etapa garante uma estimativa honesta e sem viés do desempenho real do modelo em produção.

Métrica	Valor	Interpretação
Acurácia	0.8890	88,9% das reviews classificadas corretamente

Precisão	0.8808	88,1% das previsões positivas estavam corretas
Recall	0.8998	89,9% das reviews positivas reais foram encontradas
F1-Score	0.8902	Equilíbrio perfeito entre precisão e recall

Relatório completo por classe:

Classe	Precision	Recall	F1-Score	Support
Negativo (0)	0.90	0.88	0.89	5.000
Positivo (1)	0.88	0.90	0.89	5.000
Macro avg	0.89	0.89	0.89	10.000

Consistência validação → teste: A acurácia no conjunto de teste (88,9%) ficou praticamente idêntica à validação (~88,9%), confirmando que o modelo não sofreu overfitting e generaliza bem para dados inéditos.

8. Análise de Features — Palavras com Maior Impacto

A Regressão Logística permite extrair os pesos matemáticos (**coef_**) atribuídos a cada palavra da matriz TF-IDF, tornando o modelo interpretável. Palavras com peso positivo elevado indicam sentimento positivo; pesos negativos indicam sentimento negativo.

Top palavras POSITIVAS		Top palavras NEGATIVAS	
Palavra	Peso	Palavra	Peso
great	+6.8	worst	-9.1
excellent	+6.4	waste	-6.8
best	+5.1	bad	-6.6
perfect	+4.9	awful	-6.2
amazing	+4.8	boring	-5.8
wonderful	+4.6	poorly	-4.7
hilarious	+4.5	poor	-4.6
loved	+4.4	terrible	-4.5
favorite	+4.2	dull	-4.4
710	+4.9	worse	-4.3

9. Análise de Erros — Limitações do Modelo

Para entender onde o modelo falha, foram analisados manualmente exemplos de **Falsos Positivos** (review negativa classificada como positiva) e **Falsos Negativos** (review positiva classificada como negativa).

Tipo de Erro	Causa Identificada	Exemplo
Falso Positivo (Real: Negativo Previsto: Positivo)	Erros de digitação graves e falta de contexto semântico.	"primary plotprimary directionpoor interpretation..."
Falso Negativo (Real: Positivo Previsto: Negativo)	Negação dupla e sarcasmo não detectados.	"no doubt that the indie flick is one of the better independent films"

10. Tecnologias Utilizadas

Biblioteca / Técnica	Versão / Detalhe	Finalidade
Python	3.9+	Linguagem principal
Pandas	pip	Manipulação e análise de dados
NumPy	pip	Operações numéricas
Matplotlib	pip	Geração de gráficos
Seaborn	pip	Visualizações estatísticas
Scikit-Learn	pip	Modelos, métricas e vetorização
Joblib	pip	Serialização do modelo (.pkl)
WordCloud	pip	Nuvens de palavras
Streamlit	pip	Aplicação web interativa
TF-IDF	Técnica NLP	Vetorização ponderada de textos
StratifiedKFold	Técnica ML	Validação cruzada estratificada

11. Estrutura dos Arquivos

```
projeto/
├── app.py
├── prova.ipynb
├── requirements.txt
├── model/
│   ├── modelo_final.pkl
│   └── vetorizador.pkl
├── data/
│   └── IMDB Dataset.csv
├── notebooks/
│   └── prova.ipynb
├── image/
│   └── Imagens do README.md
├── reports/
│   └── Relatorio.pdf
└── README.md
```

12. Limitações do Projeto



- **Domínio restrito:** Treinado exclusivamente com reviews de filmes; pode não generalizar para outros domínios.
- **Sarcasmo e ironia:** O modelo TF-IDF não compreende negação dupla, sarcasmo ou contexto implícito.
- **Idioma:** Funciona apenas com textos em inglês.
- **Textos curtos:** Reviews muito curtas (< 10 palavras) podem gerar classificações imprecisas.
- **Modelo estático:** Não atualiza com novos dados sem retreinamento.

13. Conclusão

O projeto demonstrou a eficácia das técnicas de Processamento de Linguagem Natural e Machine Learning para análise automática de sentimentos em avaliações de filmes. A pipeline desenvolvida desde a limpeza de dados até o deploy, seguiu boas práticas de engenharia de ML, incluindo separação estratificada, prevenção de data leakage e validação cruzada.

O modelo de **Regressão Logística com TF-IDF** se destacou entre os três algoritmos avaliados, atingindo **AUC-ROC de 0.954** na validação cruzada e **88,9% de acurácia** no conjunto de teste confirmando excelente capacidade de generalização sem overfitting.

A análise de features (coef_) revelou que o modelo aprendeu padrões semânticos coerentes: palavras como "great", "excellent" e "worst", "waste" têm os maiores pesos positivos e negativos respectivamente. A análise de erros identificou as principais limitações: sarcasmo, negação dupla e erros de digitação.



Métrica	Cross-Validation	Teste Final
Acurácia	88,9%	88,9%
AUC-ROC	95,4%	—
F1-Score	88,9%	89,0%

Projeto desenvolvido para a disciplina de Inteligência Artificial / Machine Learning — UNIMAR 2026/1 | Análise e Desenvolvimento de Sistemas